

Proyecto: Evaluación de una arquitectura multiagente basada en LLMs para el análisis de sentimientos en variedades del español

Autor: Julio Daniel Pozo García

El título cambió después de la revisión del plan. Ya no se sostiene que ningún sistema multiagente ha sido evaluado en español (afirmación difícil de defender), sino que se propone algo más concreto y verificable: comparar, de forma experimental y controlada, un enfoque monoagente contra uno multiagente, puestos a prueba sobre varias variedades del idioma. Ese cambio de enfoque tiene una consecuencia directa en el diseño: ya no basta con InterTASS PE-Perú como fuente única, así que el trabajo pasa a apoyarse en el conjunto multivariante de TASS 2020, que reúne tuits anotados de España, México, Perú, Chile, Costa Rica y Uruguay.

1. Diagrama del flujo principal

Conviene aclarar primero en qué se aparta esto de un pipeline de aprendizaje supervisado clásico. Ahí el flujo es lineal (datos, entrenamiento, predicción, métricas), aquí es un grafo de agentes con un bucle de verificación, donde el mismo modelo conversa consigo mismo en distintos roles antes de fijar una respuesta. Ese grafo se ejecuta sin variaciones sobre las seis variedades del corpus: el modelo base, los prompts y los umbrales se mantienen fijos entre países para que cualquier diferencia de desempeño pueda atribuirse al dialecto y no a un cambio silencioso en la arquitectura. También se corrigió algo que en la versión anterior del plan quedaba a medio resolver: los agentes se especializaban a la vez por etapa cognitiva (percepción, razonamiento, resolución) y por fenómeno lingüístico (sarcasmo, diminutivos, doble negación, code-switching), sin que quedara claro cómo convivían ambos criterios. Ahora el fenómeno lingüístico se resuelve dentro del agente de Percepción, como una salida estructurada que después condiciona el trabajo de los agentes siguientes.

Flujo del sistema multiagente para análisis de sentimientos (variedades del español)




Figura 1. Flujo del sistema multiagente. Se repite una vez por cada variedad dialectal del corpus, con el mismo modelo y la misma configuración.

2. Entradas, componentes principales y salida esperada

Cada instancia parte de un tuit en español tomado del conjunto multivariante de TASS 2020. La variedad dialectal (ES, MX, PE, CL, CR, UY) viaja como metadato para el análisis posterior, pero deliberadamente no se la entregamos al modelo como parte del prompt: si el sistema supiera de antemano el país, podría aprender a adivinarlo por pistas superficiales del texto en lugar de razonar sobre el sentimiento, que es lo que realmente nos interesa medir.

El texto pasa primero por el agente de Percepción, que lo lee y devuelve un JSON con los fenómenos lingüísticos que detecta (sarcasmo, diminutivo afectivo, doble negación, code-switching) junto con la evidencia textual de cada uno. Con esos indicios, el agente de Razonamiento arma una hipótesis de polaridad y la justifica. El de Resolución la convierte en una etiqueta candidata, pero aquí hay un matiz importante: la confianza de esa etiqueta no es una cifra que el LLM declara sobre sí mismo, sino el grado de acuerdo entre varias muestras del propio modelo (self-consistency), que es una medida bastante más honesta de cuánto se puede confiar en la respuesta. Con ese número, el meta-agente decide si la etiqueta queda cerrada o si conviene abrir una segunda ronda de discusión entre Razonamiento y Resolución (como máximo una, para no disparar el costo).

Por cada instancia se guarda: la etiqueta final (POS/NEG/NEU), la confianza, la variedad dialectal, las trazas de cada agente, los tokens usados y el tiempo de respuesta.

3. Criterio preliminar de evaluación

Prometer una evaluación por variedades obliga a cambiar también cómo se reporta el resultado: ya no alcanza con un solo número. Se calculará el Macro-F1 por país, el promedio entre variedades y la dispersión entre ellas, para que un buen resultado global no tape un desempeño flojo en alguna variedad en particular (la peruana es la candidata más probable a salir perjudicada, por ser la de menor representación en la literatura previa). Y para que la comparación entre monoagente y multiagente sea justa, no basta con enfrentar un sistema de una sola llamada contra otro de varias: se necesitan condiciones con un presupuesto de inferencia parecido, de modo que la mejora observada pueda atribuirse a cómo coordinan los agentes y no simplemente a que el sistema piensa más veces.

Cond.	Descripción	Propósito
B1	LLM monoagente, 1 llamada	Baseline directo.
B3	Auto-consistencia, 4 llamadas + votación	Iguala el n.º de inferencias del sistema propuesto.
B4	Multiagente completo (propuesta)	Evaluación principal.
B5 / B6	Multiagente sin un agente / con agente genérico	Ablación: aísla el aporte real de la especialización.

A esto se suman la Accuracy multiclase, la precisión y el recall por categoría, la tasa de respuestas inválidas y el costo en tokens y latencia por instancia. Para probar robustez se usarán solo perturbaciones que no cambien el sentimiento real del texto (tildes, errores de tipeo, mayúsculas, emojis equivalentes), evitando sustituir palabras de una forma que podría alterar la polaridad sin que el sistema tenga cómo saberlo. Y como las predicciones de las distintas condiciones se calculan sobre las mismas muestras, la comparación estadística se hará con bootstrap pareado, prueba de permutación y McNemar, en vez de la clásica t de Student, fijando de antemano que solo una mejora de al menos 0.02 en Macro-F1 se considerará relevante en la práctica.

4. Reproducibilidad

Los prompts se van a ajustar mirando únicamente los errores del conjunto de desarrollo, el conjunto de prueba se queda bloqueado hasta la evaluación final, precisamente para que ningún detalle del test se filtre (ni siquiera sin querer) hacia el diseño de la arquitectura. El modelo base se documenta como una variable controlada: versión exacta, cuantización, temperatura, top-p y semilla. Y como los modelos generativos no dan siempre la misma respuesta, cada condición se repetirá con varias semillas y se reportará el promedio junto con su intervalo de confianza, en vez de confiar en una sola corrida. Por cada instancia queda un registro completo (prompts, respuestas, indicios detectados, confianza, tokens y versión del modelo) que permite reconstruir cualquier resultado más adelante.

5. Riesgos técnicos previsibles

Riesgo	Cómo se atiende
Que se filtre información entre desarrollo y prueba	El conjunto de prueba se mantiene bloqueado, los prompts se ajustan solo con desarrollo y validación.
Que unas variedades tengan menos ejemplos que otras	Se reporta Macro-F1 por país y no solo un promedio global, para que ninguna quede oculta.
Que la confianza declarada por el LLM no sea fiable	Se calcula como el acuerdo entre varias muestras del modelo, no como una autodeclaración.
Comparar sistemas con distinto número de llamadas	Se incluyen condiciones (B1, B3) con un presupuesto de inferencia equiparado al multiagente.
Respuestas que no siguen el formato esperado	Salida en JSON estructurado con reintentos acotados, los fallos persistentes quedan registrados aparte.