Informe: EDA, Feature Engineering y experimento de baseline

Resumen

Con 7.267 tuits de cinco variedades, el piso de referencia es 0,19 de Macro-F1 (clase mayoritaria) y 0,56 (TF-IDF con regresión logística), y el monoagente con Salamandra-7B-Instruct queda por debajo de TF-IDF (0,479 contra 0,556) porque casi no detecta los tuits negativos. El texto limpio no cambia el resultado en ninguno de los dos.

- **Datos.** No existe partición de prueba. Perú tiene 55,2% de tuits neutros frente a un máximo de 32,0% en el resto, y no se explica solo por la época.
- **Características.** De 24, solo el léxico de valoración aporta señal distinguible (quitarlo baja 0,075). TF-IDF de palabras supera a las 24 por 0,047. Las características de mayúsculas son las más frágiles.
- **Experimento.** Macro-F1 con el tuit base y con texto limpio: TF-IDF 0,556 y 0,557; monoagente 0,479 y 0,482. Ninguna variante se distingue de la base. El monoagente queda 0,076 por debajo de TF-IDF (IC 95% de −0,102 a −0,052) y predice NEG en 6% de los tuits frente a 39% reales.
- **Qué sigue.** Reservar un subconjunto de prueba, depurar los casi duplicados y probar un prompt que corrija el sesgo a NEU antes de pasar al multiagente.

Datos y EDA

El corpus tiene 7.267 tuits de cinco variedades del español, sin conjunto de prueba, y Perú se comporta distinto de las otras cuatro: 55,2% de sus tuits son neutros frente a un máximo de 32,0% en el resto.

Variedad	Tuits	Train	Dev	NEG %	NEU %	POS %
Costa Rica (CR)	1.167	777	390	38,8	32,0	29,2
España (ES)	1.707	1.126	581	43,4	26,0	30,6
México (MX)	1.500	990	510	50,5	18,1	31,5
Perú (PE)	1.464	966	498	22,9	55,2	21,9
Uruguay (UY)	1.429	943	486	39,1	29,9	31,0
Total	**7.267**	**4.802**	**2.465**			

Las etiquetas son POS, NEG y NEU, completas. Los tuits son cortos (mediana de 92 caracteres, máximo de 146) y muy conversacionales: entre el 40% y el 63% lleva una @mención y casi ninguno tiene emojis.

Hallazgos que cambian el diseño

1. **No hay partición de prueba.** Solo existen train y dev. Aunque el LLM no se entrene, ajustar prompts y umbrales con estos datos exige reservar un subconjunto que no se toque.

2. **Perú no se explica por la época.** Dentro de los mismos meses (noviembre a enero) sigue entre 50% y 58% de NEU frente a 28% a 33% en CR y UY ($p < 0,001$). Lo que no se puede separar es el tema ni el criterio de anotación, que TASS no documenta por país.
3. **Época y país se confunden.** El 87% de los tuits de España cae en dos semanas (22 de agosto a 4 de septiembre de 2016) y el 83% de los de México en otras dos (30 de diciembre de 2016 a 12 de enero de 2017). Las diferencias por país pueden ser diferencias de tema.
4. **Piso mínimo.** Predecir siempre la clase mayoritaria da un Macro-F1 de 0,19 (0,18 a 0,24 según el país), por eso el Macro-F1 es la métrica principal y no la exactitud.
5. **Calidad.** Hay 2 textos repetidos con etiquetas distintas, 3 que aparecen en train y en dev, y 40 pares casi duplicados (8 cruzan train y dev).
6. **Potencia.** Con 20% de discrepancia entre dos sistemas, la diferencia mínima detectable es de 2,5 puntos con todo el dev y de 5,2 a 6,3 puntos por país. El umbral de mejora de 0,02 no es detectable.

Chile no está en los datos, así que el trabajo se limita a estas cinco variedades.

Feature Engineering

De 24 características lingüísticas y de superficie, solo el léxico de valoración aporta señal que se distinga de cero, y las que dependen de mayúsculas son las más frágiles. El proyecto no entrena el LLM, así que aquí se decide qué texto ve el modelo, qué pistas puede pasar el agente de Percepción y qué piso de referencia debe superar.

Qué ve el LLM. El texto cambia las @menciones por `@USUARIO` y los enlaces por `URL`, y colapsa espacios. No se tocan mayúsculas, puntuación, alargamientos ni emojis, porque son señales de tono, y no se le dice la variedad.

Catálogo. 24 características en cinco grupos: estructural (6), expresividad (7), conversacional (4), fenómeno (4) y léxico (3). Los fenómenos son diminutivo, negación, mezcla de idiomas y risa. El léxico es una lista propia de unas 30 palabras por lado, sin validar.

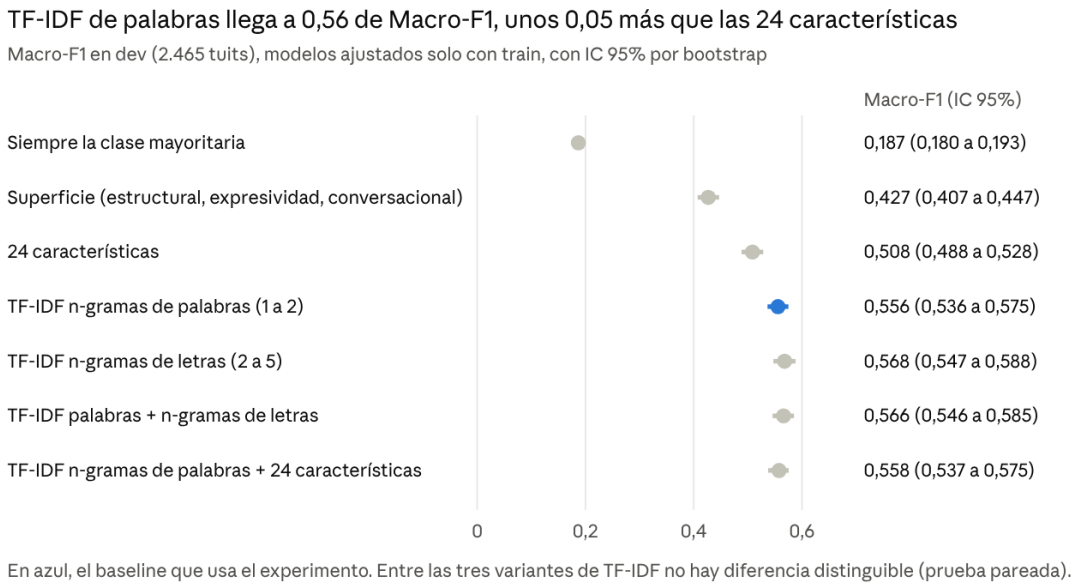
Qué aporta cada grupo

- Quitar el léxico baja el Macro-F1 en 0,075 (IC 0,054 a 0,096). Quitar cualquier otro grupo no cambia nada distinguible.
- Solo con las 3 características de léxico se llega a 0,48, frente a 0,51 con las 24.
- Emojis, emoticonos, enlaces y número de oraciones no aportan.
- Como reglas aisladas, las banderas de Percepción dicen poco, salvo la doble negación: 55,1% de NEG entre los tuits que la activan, frente a 39,1% en total.

Atajos. Las características conversacionales (menciones, enlaces, hashtags) se relacionan más con el país que con el sentimiento. Y solo con el texto, un clasificador adivina el país con Macro-F1 de 0,38 frente a 0,20 al azar, así que no pasarle la variedad al LLM no garantiza que no la infiera.

Robustez. Al poner todo en mayúsculas, el modelo de 24 características cae 0,084 y TF-IDF no cambia. Las letras alargadas bajan 0,026 a TF-IDF de palabras. Un LLM no es invariante a mayúsculas, así que esas dos perturbaciones son las más informativas para medirlo.

Comparación. TF-IDF de palabras supera a las 24 características por 0,047 (IC 0,025 a 0,068). Entre TF-IDF de n-gramas de palabras (1 a 2), de n-gramas de letras (2 a 5, dentro de cada palabra) y su combinación no hay diferencia distinguible, con bootstrap pareado.



docs/features/tablas/comparacion_representaciones.csv · dev, 2.465 tuits

Diseño del experimento

El experimento compara una línea base contra una variante de los datos, con el mismo modelo y los mismos tuits de dev: lo único que cambia es el texto de entrada. Como el LLM no se entrena, el texto que recibe es la única palanca del diseño.

Variante principal: texto limpio. Quita la información de tono (mayúsculas, tildes, alargamientos y emojis) para medir cuánto depende el resultado de ella. Un ejemplo real de dev:

- Base: `No debí cogerme la cara con las manos suciaaaaas!!`
- Limpio: `no debi cogerme la cara con las manos sucias!!`

Además se prueba cada componente por separado, para saber cuál pesa si la variante cambia algo.

Variante	Qué cambia
Base	El tuit como lo ve el LLM: `@USUARIO`, `URL` y espacios colapsados. Conserva mayúsculas, tildes, alargamientos y emojis
Limpio	Minúsculas, sin tildes (la ñ se conserva), sin letras alargadas y sin emojis
Solo minúsculas	Solo el paso a minúsculas

Variante	Qué cambia
Solo sin tildes	Solo quita tildes y diéresis
Solo sin alargamientos	`suciaaaaas` pasa a `sucias`
Solo sin emojis	Quita los emojis
Extra: sin `@USUARIO` y `URL`	Quita los marcadores conversacionales, que se ligan más al país que al sentimiento

Cuánto toca cada variante. Sobre los 2.465 tuits de dev, cuántos textos cambian respecto de la base:

Variante	Tuits que cambian	% de dev
Limpio	2.408	97,7
Solo minúsculas	2.358	95,7
Solo sin tildes	1.423	57,7
Extra: sin `@USUARIO` y `URL`	1.212	49,2
Solo sin alargamientos	119	4,8
Solo sin emojis	13	0,5

Esto anticipa qué variantes pueden mover algo: casi no hay emojis, y TF-IDF ya pasa todo a minúsculas.

Modelo. Hay dos modelos. El baseline es un clasificador clásico: TF-IDF de palabras (1 a 2 palabras) con regresión logística balanceada, sin ajustar hiperparámetros. Se ajusta solo con train y se mide solo en dev (2.465 tuits). La variante se aplica igual a train y a dev. El monoagente usa las mismas funciones de variante y la misma evaluación.

Monoagente con LLM. Salamandra-7B-Instruct (`BSC-LT/salamandra-7b-instruct`, revisión `a3ed5452fafb3698a0423b1a18bfb5888f4e611b`), con cuantización a 4 bits y sin fine-tuning. Clasifica cada tuit en una sola llamada, zero-shot, con salida JSON, decodificación determinista y hasta 2 reintentos si la salida no se entiende. El prompt (`B1-v1`) no incluye la variedad y no se ajustó con dev. Las salidas que siguen sin entenderse cuentan como NEU (7 de 4.930).

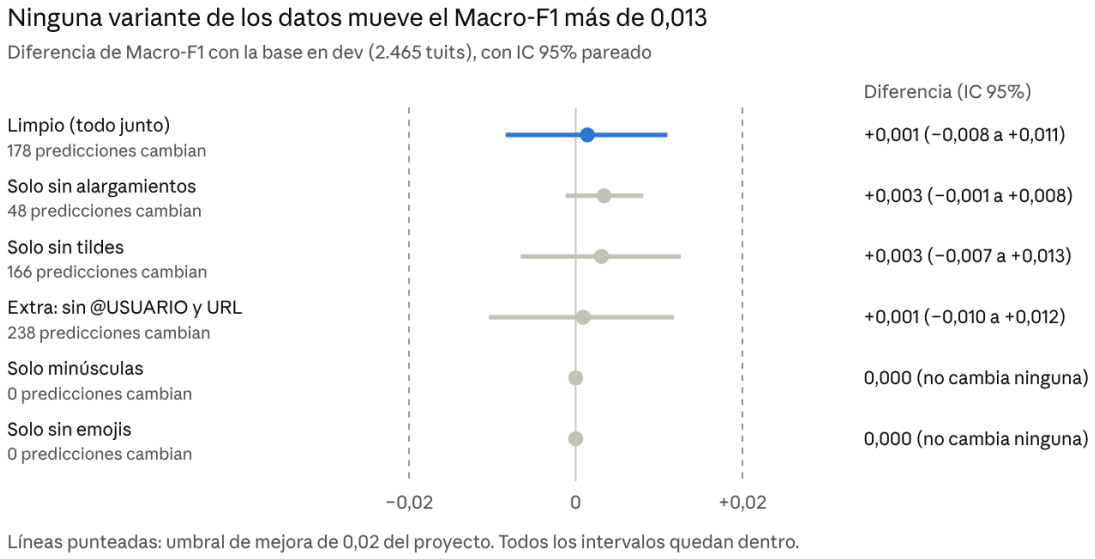
Métrica. Macro-F1 con intervalo del 95% por bootstrap (2.000 remuestreos). La comparación entre variante y base usa bootstrap pareado sobre la diferencia, porque ambas se miden sobre los mismos tuits. La exactitud queda como métrica secundaria.

Lo que este diseño no cubre. No existe partición de prueba: todo se reporta en dev y no se ajustó nada con él, pero un experimento final con el LLM sí necesita reservar un subconjunto.

Resultados

El texto limpio no cambia el rendimiento del baseline clásico: Macro-F1 de 0,557 contra 0,556 con la base, con una diferencia pareada de +0,001 (IC 95% de −0,008 a +0,011).

Ámbito	Base	Limpio	Diferencia (IC 95%)	Predicciones que cambian
Todas	0,556	0,557	+0,001 (−0,008 a +0,011)	178 de 2.465
CR	0,586	0,586	0,000 (−0,020 a +0,020)	16 de 390
ES	0,538	0,539	+0,001 (−0,020 a +0,020)	49 de 581
MX	0,559	0,557	−0,002 (−0,027 a +0,023)	41 de 510
PE	0,501	0,503	+0,002 (−0,020 a +0,023)	41 de 498
UY	0,567	0,576	+0,008 (−0,011 a +0,026)	31 de 486



docs/experimento/tablas/diferencias_pareadas_variantes.csv · dev, 2.465 tuits

- **Cambia mucho texto y poco resultado.** El texto limpio altera 178 de 2.465 predicciones (7,2%), pero en ambas direcciones: 72 tuits pasan de error a acierto y 69 de acierto a error.
- **Ninguna variante se distingue de la base**, ni en total ni por variedad. En el total, los intervalos excluyen un cambio de 0,02 o más. Por variedad (390 a 581 tuits) no lo excluyen, porque son demasiado anchos.
- **Dos variantes no pueden mover nada por construcción.** El vectorizador ya pasa a minúsculas, y solo el 0,2% de los tuits tiene emojis.
- **Perú sigue siendo la variedad más baja** con ambos textos (0,501 y 0,503), en línea con su exceso de neutros.
- **Lo que esto no dice.** Es el piso clásico. Si el texto limpio mueve o no a un LLM se midió aparte, en la sección siguiente.

Cada componente por separado (TF-IDF)

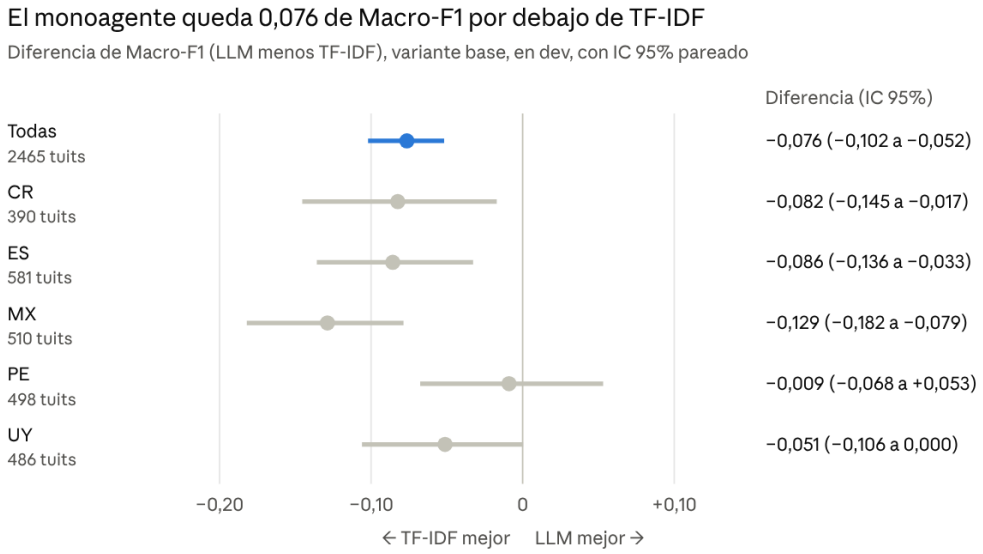
Diferencia de Macro-F1 contra la base en todo dev, con IC 95% pareado. "A favor" son tuits que pasan de error a acierto con la variante, y "en contra", los que pasan de acierto a error.

Variante	Predicciones que cambian	A favor	En contra	Diferencia (IC 95%)
Limpio	178	72	69	+0,001 (−0,008 a +0,011)
Solo minúsculas	0	0	0	0,000
Solo sin tildes	166	70	63	+0,003 (−0,007 a +0,013)
Solo sin alargamientos	48	21	13	+0,003 (−0,001 a +0,008)
Solo sin emojis	0	0	0	0,000
Extra: sin `@USUARIO` y `URL`	238	97	96	+0,001 (−0,010 a +0,012)

Ninguna se distingue de la base. Minúsculas y emojis no cambian ni una predicción, por construcción. Sin alargamientos es la que más se acerca a una diferencia (p = 0,146), todavía lejos.

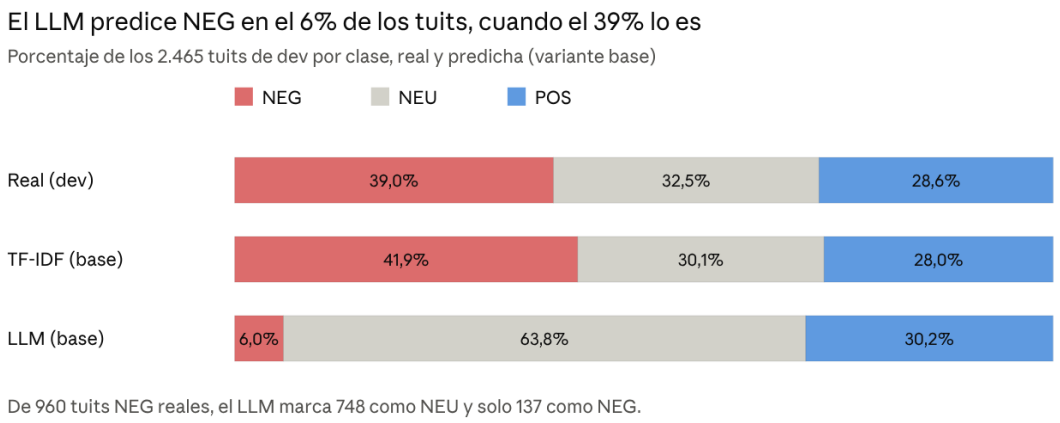
Monoagente con Salamandra-7B-Instruct

El monoagente queda por debajo del baseline clásico: Macro-F1 de 0,479 contra 0,556, una diferencia pareada de −0,076 (IC 95% de −0,102 a −0,052). Se reporta tal cual, como se fijó antes de ver los resultados.



docs/experimento/llm/tablas/llm_vs_clasico_pareado.csv · dev, 2.465 tuits

- **Por variedad.** La diferencia es clara en CR, ES y MX. En Perú no se distingue, y Uruguay queda en el límite (el intervalo llega a 0,000). Con una corrección de Bonferroni para las 5 variedades siguen siendo distintas ES y MX, y CR queda en el límite.
- **El LLM casi no detecta NEG.** Cuando dice NEG casi siempre acierta (precisión de 0,93), pero encuentra pocos (recobrado de 0,14).



docs/experimento/llm/tablas/distribucion_predicha.csv · dev, 2.465 tuits

- **Dónde gana y dónde pierde.** F1 de NEG: 0,248 contra 0,629 de TF-IDF. En POS el LLM gana (0,675 contra 0,586) y en NEU también (0,516 contra 0,451), aunque con baja precisión en NEU (0,39).
- **Perú.** Es donde mejor le va (0,492, sin diferencia distinguible con TF-IDF). Su clase mayoritaria es NEU, que es lo que el modelo responde ante la duda. Es consistente con el sesgo, pero no se probó por separado.
- **Texto limpio.** Tampoco cambia al LLM: 0,482 contra 0,479, una diferencia de +0,003 (IC 95% de −0,009 a +0,014). Cambia 206 de 2.465 predicciones, 87 a favor y 84 en contra, y ningún ámbito se distingue de la base.
- **Hipótesis, no resultado.** Que el sesgo a NEU venga del prompt `B1-v1` y no del modelo no se probó. Un prompt distinto es el siguiente experimento natural.

Texto limpio en el monoagente, por variedad. Macro-F1 y diferencia pareada (limpio menos base):

Ámbito	Base	Limpio	Diferencia (IC 95%)	Predicciones que cambian
Todas	0,479	0,482	+0,003 (−0,009 a +0,014)	206 de 2.465
CR	0,504	0,510	+0,006 (−0,026 a +0,040)	35 de 390
ES	0,453	0,467	+0,015 (−0,008 a +0,038)	46 de 581
MX	0,430	0,424	−0,006 (−0,031 a +0,021)	52 de 510
PE	0,492	0,485	−0,007 (−0,040 a +0,024)	54 de 498
UY	0,516	0,521	+0,005 (−0,013 a +0,023)	19 de 486

Precisión, recobrado y F1 por clase (variante base, todo dev):

Clase	TF-IDF: precisión / recobrado / F1	LLM: precisión / recobrado / F1
NEG	0,607 / 0,653 / 0,629	0,932 / 0,143 / 0,248

Clase	TF-IDF: precisión / recobrado / F1	LLM: precisión / recobrado / F1
NEU	0,469 / 0,435 / 0,451	0,389 / 0,765 / 0,516
POS	0,593 / 0,580 / 0,586	0,656 / 0,694 / 0,675

Matriz de confusión del LLM (filas: real; columnas: predicho):

Real \ Predicho	NEG	NEU	POS
NEG	137	748	75
NEU	7	612	181
POS	3	213	489

La fila NEG concentra la pérdida: 748 de 960 negativos salen como NEU. Al revisar 10 ejemplos de ese error en la Parte B del cuaderno 04, algunos tuits parecen neutros de verdad ("Buenos días, ya casi se acaban mis vacaciones"), así que parte del error puede venir de la etiqueta y no solo del prompt. Es una muestra de 10, no una medición.

Evidencia de ejecución

La corrida del monoagente se hizo en Colab y los archivos están en el repositorio. Las tablas se recalcularon aquí desde las predicciones.

Elemento	Valor
Modelo	`BSC-LT/salamandra-7b-instruct`, revisión `a3ed5452fafb3698a0423b1a18bfb5888f4e611b`, 4 bits
Fecha	23 de octubre de 2026, commit 9945019
Predicciones	4.930 (2.465 tuits × 2 variantes), sin duplicados
Intentos	4.921 acertaron al primero y 9 necesitaron 3 intentos
Salidas inválidas	7 (0,14%), contadas como NEU
Verificación	12 de 12 valores de Macro-F1 recalculados coinciden con las tablas
Archivos	`docs/experimento/llm/predicciones_llm.csv`, `docs/experimento/llm/tablas/` y `notebooks/04_experimento_baseline.ipynb`
Prompt	`B1-v1`, sin cambios entre corridas
No registrado	GPU, versiones de librerías y tiempo por variante
Huella del archivo	sha1 a60273015b47d9517a9f31f2a7cd766d6026a313 de predicciones_llm.csv
Análisis	la Parte B de notebooks/04_experimento_baseline.ipynb lee esos

Elemento	Valor
	archivos y no vuelve a correr el modelo; recalcula la huella y las cifras

Limitaciones y amenazas a la validez

La limitación principal es que el monoagente se corrió una vez, con un solo prompt sin ajustar, así que su resultado dice más del prompt B1-v1 que del modelo.

- **Una corrida y un prompt.** Hay una sola corrida determinista (temperatura 0) y no se midió la variación entre prompts ni entre ejecuciones.
- **Sin partición de prueba.** Todo se reporta en dev. No se ajustó ningún hiperparámetro con él, pero los prompts del LLM sí se ajustarán con datos, y eso exige reservar un subconjunto que no se toque.
- **Potencia por variedad.** Con 390 a 581 tuits por variedad, los intervalos de la diferencia miden unos ±0,02. Solo en el total (2.465 tuits) se descarta un cambio de 0,02 o más.
- **Comparaciones múltiples.** Son 6 variantes en 6 ámbitos, sin corrección. Como ninguna resulta distinta de la base, la corrección no cambiaría la conclusión.
- **Variantes escritas por mí.** El texto limpio y las perturbaciones de robustez son implementaciones sencillas. Otra definición (por ejemplo, tratar de otra forma la ñ o los alargamientos de dos letras) puede dar otras cifras.
- **Léxico y fenómenos sin validar.** El léxico es una lista propia de unas 30 palabras por lado, y las reglas de fenómenos no se anotaron a mano todavía.
- **Perú y época.** El exceso de neutros en Perú no se explica solo por el período, pero no se puede separar del tema ni del criterio de anotación. Las diferencias por país deben leerse con ese contexto.
- **Datos.** Quedan 2 textos con etiquetas en conflicto y 40 pares casi duplicados (8 cruzan train y dev), que este experimento no depuró.
- **Sesgo a NEU sin explicar.** El LLM predice NEG en 6% de los tuits frente a 39% reales. Se atribuye al prompt, pero no se probó.
- **Registro incompleto.** No se guardaron la GPU, las versiones de librerías ni el tiempo por variante.
- **Pocas diferencias resisten la corrección.** Con Bonferroni solo ES y MX se distinguen de TF-IDF por variedad; CR queda en el límite.

Siguientes pasos

El monoagente ya tiene una línea de base medida. Lo que sigue es entender por qué pierde y recién entonces pasar al multiagente.

1. **Reservar un subconjunto de prueba** y depurar los 2 textos en conflicto y los casi duplicados que cruzan train y dev, antes de ajustar nada.
2. **Probar un prompt que corrija el sesgo a NEU**, ajustándolo en desarrollo y reportándolo en el subconjunto reservado.
3. **Más corridas:** al menos 2 prompts y, si hay muestreo, las semillas 13, 42 y 2026, para tener variación y no una sola cifra.

4. **Variante con ruido** (mayúsculas, tipeo, alargamientos), que es donde un LLM puede mostrar diferencias que el texto limpio no mostró.
5. **Condiciones multiagente B3 a B6** sobre el mismo protocolo y las mismas variantes.
6. **Registrar el entorno** (GPU, versiones, tiempo) en cada corrida.
7. **Pendientes de datos:** anotar a mano la muestra de fenómenos y cambiar el léxico propio por uno validado.